

2026 비전공 교원 대상 AI 특강 (하계)

<기계학습 딥러닝 분야>

실습: 2026년 8월 6일 Foundation Model
소프트웨어학과 김광수 교수
인공지능학과 장승우 박사과정

Foundation Model

환경 설정

Foundation Model


실습 환경

1. 세션 종료 안 하셨다면



```
$ Terminal 1 × +  
work@main1[DipKN9a1-session]:/workspace/SKKU_SUMMER_LECTURE$ cd /workspace/SKKU_SUMMER_LECTURE/  
work@main1[DipKN9a1-session]:/workspace/SKKU_SUMMER_LECTURE$ git pull
```

2. 종료 하셨다면



```
$ Terminal 1 × +  
work@main1[DipKN9a1-session]:/$ cd workspace/  
work@main1[DipKN9a1-session]:/workspace$ git clone https://github.com/SE93W0/SKKU_SUMMER_LECTURE
```

Foundation Model

실습 환경

1 Day2 폴더 열기

Name	Modified
Day1	16h ago
Day2	59s ago

2 00_install.ipynb 실행

Name	Modified
00_install.ipynb	1m ago
01_data_preparati...	4d ago
02_Image_Inferen...	4d ago
03_Zero_Shot_Cla...	2h ago
04_Fine_Tuning.ip...	1h ago
05_LoRA.ipynb	1h ago
cat.jpg	4d ago

라이브러리 설치

3

```
!python -m pip install --upgrade pip
!pip install -U "transformers==4.49.0"
!pip install -U opencv-python-headless==4.8.1.78
!pip install timm
!pip install -U bitsandbytes
!pip install --user --ignore-installed -U ipywidgets jupyterlab_widgets
```

4

토큰 설정 및 내려받기

```
##### 0. Hugging Face 토큰 #####
# 아래 마중표 안에 토큰을 붙여넣으세요 (바탕두면 입력창이 나타납니다)
# 발급: huggingface.co -> 프로필 -> Settings -> Access Tokens -> New token (Read)

HF_TOKEN = "" # 예: "hf_xxxxxxxxxxxxxxxxxxxxxx"

# -----
import os

os.environ["HF_HUB_DISABLE_PROGRESS_BARS"] = "1"

import time, random, getpass
import datasets
from huggingface_hub import snapshot_download, scan_cache_dir
from datasets import load_dataset

token = HF_TOKEN.strip() or os.environ.get("HF_TOKEN", "")

if not token:
    print("토큰을 입력하세요 (없으면 그냥 Enter)")
    print("입력하는 동안 화면에 표시되지 않습니다 - 정상입니다")
    try:
        token = getpass.getpass("HF_TOKEN: ").strip()
    except Exception:
        print("입력창을 사용할 수 없습니다 - HF_TOKEN 변수에 직접 입력하세요")
        token = ""

if token:
    os.environ["HF_TOKEN"] = token
    os.environ["HUGGING_FACE_HUB_TOKEN"] = token # 구버전 호환
    try:
        from huggingface_hub import HfApi
        print("토큰인 완료:", HfApi().whoami()["name"], "\n")
    except Exception:
        print("토큰 설정됨 (계정 확인 실패 - 토큰을 다시 확인하세요)\n")
    else:
        print("토큰이 이미 지정 - 이제 데이터셋을 내려받을 수 있습니다")
```

Hugging Face 토큰

계정 인증 — 요청 제한 완화와 제한 모델 접근

토큰이 필요한 이유

① 요청 제한 완화

- Hub는 5분 단위로 요청 횟수를 제한
- 익명 요청은 IP 기준 집계 — 같은 네트워크끼리 합산
- 다수가 동시에 내려받으면 429 오류 발생
- 인증 시 계정별 할당량 적용

② 제한 모델 접근

- 일부 모델은 사용 조건 동의 필요 (Llama · Gemma 등)
- 모델 페이지에서 동의한 계정의 토큰이 있어야 접근 가능
- 비공개 모델도 권한 있는 계정의 토큰 필요

발급 절차

- ① huggingface.co 가입 · 로그인
- ② 우측 상단 프로필 → Settings
- ③ 좌측 메뉴 Access Tokens
- ④ New token → 이름 입력 → 권한 Read
- ⑤ 생성된 hf_... 문자열 복사

오류 구분


- 401** — 토큰 미설정 또는 무효
- 403** — 사용 조건 동의 필요
- 429** — 요청 제한, 잠시 후 재시도

Foundation Model

개요

Foundation Model


AI의 발전과 Foundation Model



Foundation Model이란?

다양한 AI의 기반이 되는 대규모 사전학습 모델

- 광범위한 데이터로 사전학습된 대규모 모델
- 다양한 하위 작업(downstream task)에 적응·활용 가능
- **적응 방식** — 그대로 활용(추론) 또는 미세조정
- 언어·이미지·음성 등 여러 양식(modality)에 적용



Foundation Model


사전학습 모델의 이점

이미 학습된 것 위에 필요한 판단만 추가

이미 학습된 것

- 경계와 윤곽을 구분
- 질감과 패턴을 인식
- 덩어리와 배경을 분리

↑ 수억 장을 보며 익힘



추가로 학습할 것

- “이 경계가 종양이다”
- “이 형태가 나선은하다”
- “이 균열이 불량이다”

↑ 수십 ~ 수백 장이면 충분


항목	처음부터 학습	사전학습 모델 활용
시작 상태	백지	대규모 데이터로 이미 학습됨
필요 데이터	수만 장 이상	수십 ~ 수백 장
학습 시간	수일 ~ 수주	수 분 ~ 수 시간

Foundation Model


추론과 미세조정

모델을 쓰는 방법은 두 가지 — 추론과 미세조정

추론



미세조정



언제 무엇을 쓰나

상황별 선택 기준

추론이면 충분한 경우

- 일반적인 작업 (흔한 사물·동물 등)
- 잘 맞는 모델이 이미 존재
- 빠른 결과만 필요

미세조정이 필요한 경우

- 특수한 분야 (특정 세포·부품·문서 등)
- 기존 모델이 내 데이터에 부정확
- 내 기준·라벨로 분류 필요

판단 순서

- 먼저 추론 시도 → 부족하면 미세조정
- 직접 학습은 맞는 모델이 없을 때만

Foundation Model

의료영상 분할

SAM은 일반적인 이미지에 강하나 의료영상에는 약함
→ 처음부터 학습하지 않고, SAM을 의료영상에 맞게 적응시킬 수 있을까?

어떻게 확장했나

토대 — 대규모로 학습된 분할 모델 SAM을 그대로 사용

① **인코더 동결** — 원래 지식 보존, 가벼운 어댑터(LoRA)만 학습

② **방법론 추가** — 2단계 계층적 디코더로 의료 사전지식 반영

③ **프롬프트 불필요** — 전문가 개입 없이 자동 분할

핵심 — 백본은 그대로, 소수 모듈만 학습 → 적은 데이터로 특화

데이터

복부 CT 다장기(Synapse), 심장·전립선 MRI · 8개 장기 · 라벨 극소량(전립선 3 케이스)

모델

SAM(ViT 백본) + LoRA 어댑터 + 계층적 디코더 · 인코더 동결

결과

슬라이스 10%로 평균 Dice 80.35% (기존 대비 +5%p) · 전체 데이터 시 86.49%, 전용 모델도 능가

Unlabeled	Labeled	Mean Dice (%)	Methods
		78.27	SOTA Semi-Supervised Methods
		86.83 ↑	H-SAM
		75.57	SOTA SAM Variants
		80.35 ↑	H-SAM

슬라이스 10%만으로도 기존 SAM 변형들을 능가

Foundation Model

은하 이미지 분류

천문 이미지는 라벨이 적고, 지금껏 대부분 모델을 처음부터 학습 — 자연 이미지로 학습된 공개 파운데이션 모델을 은하 분류에 가져다 쓸 수 있을까?


어떻게 활용했나

토대 — 공개된 비전 파운데이션 모델(DINOv2 등)을 그대로 사용

방식 1 — 백본 동결 + 분류기만 학습 (수십 초면 완료)

방식 2 — 부족하면 LoRA로 일부만 미세조정 (파라미터 5% 미만)

핵심 — 처음부터 학습 안 함, 있는 모델을 가져와 적은 라벨로 특화



데이터

은하 형태 분류(광학, GalaxyMNIST 1만 장 · 4종) + 전파 은하(RGZ)

모델

공개 파운데이션 모델(DINOv2·CLIP 계열, 그대로) + 분류기 / LoRA

결과

광학 은하 분류 지도학습 대비 최대 +15%, 라벨 10%로 F1 0.87 · 전파 은하

Examining vision foundation models for classification and detection in optical and radio astronomy, Lastufka et al., Astronomy & Astrophysics 703, A217 (2025)

뇌 시각피질 해석

사람이 사진을 볼 때 뇌는 어떻게 반응할까? — 뇌 예측 모델을 새로 만들지 않고, 공개된 AI 모델(CLIP)을 가져와 뇌 반응을 설명할 수 있을까?

어떻게 활용했나

토대 — 이미지-언어를 함께 학습한 공개 모델 CLIP을 그대로 사용


방식 — 사람에게 보여준 사진을 CLIP에도 입력, 이미지 특징 추출

학습 — CLIP은 그대로, 뇌 반응 예측 모델만 학습

비교 — 언어 없이 이미지만 학습한 기존 모델과 대조

발견 — 언어까지 배운 AI가 인간 뇌 시각 처리를 더 잘 닮음

핵심 — AI를 만든 게 아니라, 뇌를 이해하는 도구로 활용



CLIP 기반 모델이 고차 시각피질 반응의 최대 79%를 설명

데이터

사람들이 실제 사진을 볼 때 측정한 뇌 반응(fMRI, Natural Scenes Dataset)

모델

공개 CLIP(그대로) + 뇌 반응 예측 모델(복셀 단위)

결과

고차 시각피질 반응 최대 79%(R²) 설명 · 언어 없이 학습한 기존 모델을 크게 능가

Better models of human high-level visual cortex emerge from natural language supervision with a large and diverse dataset, Wang et al., Nature Machine Intelligence (2023)

Foundation Model

동물 행동 분류

카메라 트랩이 만든 수십만 장의 야생동물 사진 — AI 모델을 새로 학습시키지 않고, 공개된 파운데이션 모델을 그대로 가져와 동물의 행동을 분류할 수 있을까?

어떻게 활용했나

토대 — 공개된 비전-언어 파운데이션 모델(CLIP·SigLIP·CogVLM 등 6종)

방식 — 미세조정 없이(제로샷), 텍스트로 행동을 묻고 이미지와 대조

예 — "먹는 중 / 이동 중 / 쉬는 중" 중 무엇인지 판별

추가 실험 — 촬영 시간(주간·야간)·종 이름을 함께 주면 정확도 변화

핵심 — 학습조차 안 함, 있는 모델에 질문만 던져 활용



데이터

알프스 야생동물(CREA Mont-Blanc, 13만여 장) + 세렝게티 · 행동 3종 (먹기·이동·휴식)

모델

공개 비전-언어 모델 6종 (CLIP·SigLIP·CogVLM 등), 미세조정 없음

결과

전용 학습 없이 최고 모델 96% 정확 · 질문(프롬프트) 방식이 성능에 큰 영향

Zero-shot animal behaviour classification with vision-language foundation models, Dussert et al., Methods in Ecology and Evolution (2025)

Foundation Model Hugging Face란?



Hugging Face

전 세계 AI 모델을 모아 제공하는 개방형 플랫폼

- 기업·대학·연구기관이 개발한 모델을 무료 공개
- 범용 모델과 분야 특화 모델(의료·위성·생명 등)을 모두 제공

전문 지식 없이 사용
만들어진 모델을 그대로 활용

최신·다양한 모델
내 분야 모델을 찾아 바로 사용

직접 내려받아 실행
데이터 외부 유출 없음

무료 · 오픈 라이선스
연구 · 교육 목적 대부분 무상 이용

Hub에는 무엇이 있나

Hugging Face Hub — 모델·데이터·데모가 모인 개방형 플랫폼

Models

미리 만들어진 AI 모델

- 이미지·텍스트·음성 등 작업 별 최신 모델
- 모델 카드로 용도·한계·편향 안내
- 작업·언어별로 검색 가능

Datasets

학습·평가용 공개 데이터

- 다양한 분야·형식의 데이터
- 데이터셋 카드로 출처·구성 설명
- 브라우저에서 데이터 미리 보기

Spaces

브라우저 체험 데모

- 설치 없이 바로 실행해보는 앱
- 모델을 직접 눌러보며 확인
- 코드 없이 결과 체험

규모 — 모델 240만 · 데이터셋 73만 · 데모 100만 개 이상 (2026년 기준, 모두 공개)

Foundation Model

데이터 업로드

실습 데이터 준비

세 가지 데이터 준비 방법

URL 입력

웹 이미지 주소를 코드에
직접 지정

▶ 준비 없이 즉시 시작

Hub 데이터셋

공개 데이터셋을 내려받아
사용

▶ 라벨 포함 데이터 필요

직접 업로드

보유 이미지를 작업 폴더에
올려 사용

▶ 연구 데이터 활용

Foundation Model

URL 입력

웹 이미지 주소를 파일 경로 대신 직접 지정

주소 확보

- 웹 이미지에서 우클릭 → 이미지 주소 복사
- 주소가 .jpg · .png 로 끝나는지 확인
- 페이지 주소가 아닌 이미지 자체의 주소 사용
- 로그인에 필요한 사이트는 접근 불가

불러오기

```
import requests
from PIL import Image

url = "https://.../cat.jpg"
image = Image.open(requests.get(url, stream=True).raw)
```


- 주소에서 이미지를 받아 그대로 열기
- 업로드 과정 불필요
- 화면에 이미지가 표시되면 정상



Foundation Model

Hub 데이터셋 찾기

Datasets 탭에서 공개 데이터셋 검색·확인



검색 절차

- ① huggingface.co → Datasets 탭
- ② 좌측 Tasks 필터에서 작업 선택 (Image Classification 등)
- ③ 정렬 기준 선택 — 다운로드 · 트렌딩 · 최신
- ④ 데이터셋 카드에서 용도·출처·라이선스 확인

선택 시 확인 사항

- **미리보기(Data Studio)** — 브라우저에서 내용 직접 확인
- **규모** — 이미지 수, 파일 용량
- **구성** — 이미지와 라벨의 열 이름
- **이름 형식** — 제작자/데이터셋명

데이터셋 불러오기

load_dataset 함수로 Hub 데이터셋 내려받기

```
from datasets import load_dataset

ds = load_dataset(
    "AI-Lab-Makerere/beans",
    split="train"
)
```

첫 인자 — 데이터셋 이름 (제작자/데이터셋명)

split — 사용할 구간 지정

split 의미

- **train** — 학습용 구간
- **validation** — 검증용 구간
- **test** — 시험용 구간
- 생략 시 전체 구간을 함께 불러옴
- 구간 구성은 데이터셋마다 상이 — 카드에서 확인

- 첫 실행은 내려받기로 시간 소요 — 이후 저장된 파일 재사용

데이터셋 구조 확인

불러온 데이터의 개수와 구성 항목 파악

```
ds

# 출력 예시
Dataset({
  features: ['image', 'labels'],
  num_rows: 1034
})
```

출력 항목

- **features** — 각 항목의 구성 열
 - **image** — 이미지 데이터
 - **labels** — 정답 분류 번호
- **num_rows** — 전체 이미지 수
- 열 이름은 데이터셋마다 상이 — label · labels 등
- 이후 코드에서 이 열 이름을 그대로 사용

- 구조 확인은 필수 절차 — 열 이름을 알아야 이미지·라벨 접근 가능
- 개별 항목 확인 — **ds[0]**

이미지와 라벨 확인

개별 항목에서 이미지와 정답 추출

이미지 확인

```
image = ds[0]["image"]  
image
```

- `ds[0]` — 첫 번째 항목 선택
- `["image"]` — 이미지 열 지정
- 마지막 줄에 변수명만 입력 → 화면에 표시

라벨 확인


```
ds[0]["labels"]  
ds.features["labels"].names
```

- 첫 번째 줄 — 정답 분류 번호 (예: 0)
- 두 번째 줄 — 번호에 대응하는 이름 목록
- 번호와 이름을 함께 확인해야 결과 해석 가능

Foundation Model

직접 업로드

이미지를 작업 폴더에 업로드




절차

- ① 좌측 파일 탐색기에서 작업 폴더 확인
- ② 업로드 버튼 클릭 또는 파일을 끌어다 놓기
- ③ 목록에 파일이 나타나면 업로드 완료
- ④ 파일명 확인 — 코드에서 그대로 사용

업로드한 이미지 열기

파일 경로를 복사하여 이미지 확인



경로 복사

- ① 파일 우클릭 → 메뉴 하단 Copy Path 선택
- ② 복사된 경로를 따옴표 안에 붙여넣기
- ③ 경로 예시 — "SKKU/Cat_August_2010.jpg"

불러오기

```
from PIL import Image

image = Image.open("Cat_August_2010.jpg")
image
```

- **Image.open** — 파일을 이미지로 불러오기
- 마지막 줄에 변수명만 입력 → 화면에 이미지 표시
- 이미지가 보이면 경로 정상


Foundation Model

폴더 단위 업로드 방법

폴더 생성 후 업로드 또는 ZIP 압축 후 해제

방법 1 폴더 생성 후 업로드

- ① 파일 탐색기에서 **새 폴더** 버튼 클릭
- ② 폴더 이름 입력 — **영문 권장** (예: dataset)
- ③ 폴더 더블클릭 후 진입
- ④ **업로드 버튼(↑)**으로 이미지 선택 — 여러 개
동시 선택 가능



방법 2 압축 파일 업로드

- ① 내 PC에서 이미지 폴더를 **ZIP**으로 압축 —
우클릭 → 압축
- ② ZIP 파일 **단일 업로드**
- ③ 노트북에서 **압축 해제**

실행 압축 해제 코드

```
import zipfile

with zipfile.ZipFile("dataset.zip") as z:
    z.extractall("dataset")
```

Foundation Model

폴더 구조가 데이터셋 구조를 결정

폴더를 나누면 폴더 이름이 정답 라벨이 된다

① 한 폴더에 모은 경우

```
dataset/  
  a.jpg    b.jpg  
  c.jpg  
features: ['image']
```

- 구분 근거 없음 — 라벨 열 미생성
- 이미지만 불러와짐
- 정답이 불필요한 추론에 사용

② 라벨별로 나눈 경우

```
dataset/  
  cat/    a.jpg    b.jpg  
  dog/    c.jpg  
features: ['image', 'label']
```

- 폴더 이름이 정답 라벨로 인식 — cat · dog
- 사진마다 소속 폴더 이름이 정답
- 학습(미세조정)에 사용

```
# 두 경우 모두 동일 — 폴더 경로만 지정  
from datasets import load_dataset  
ds = load_dataset("path/to/folder")  
ds = load_dataset("imagefolder", data_dir="path/to/folder")
```

학습용·평가용 데이터의 사전 분리

학습용과 평가용 데이터의 사전 분리

폴더 구조

```
dataset/  
  train/  
    cat/  
    dog/  
  test/  
    cat/  
    dog/
```

- 상위 폴더 — **구간** (train · test)
- 하위 폴더 — **라벨** (cat · dog)
- 두 계층 모두 필요

```
ds["train"]  
ds["test"]
```

- 구간별로 나누어 접근

구간을 나누는 이유

- **train** — 모델 **학습**에 사용하는 데이터
- **test** — 학습에 쓰지 않고 **성능 평가**에만 사용
- 학습 데이터로 평가 시 **성능 과대평가** — 학습한 내용의 반복에 불과
- 미사용 데이터로 평가해야 **일반화 성능** 확인 가능
- 검증용(**validation**) 구간을 추가로 두기도 함

Foundation Model

metadata 파일 — 폴더 구조로 표현되지 않는 정보 지정

file_name 열로 이미지와 정보를 연결

배치와 작성

```
dataset/  
  metadata.csv  
  0001.png
```

```
# metadata.csv  
file_name,species,date  
0001.png,cheetah,2024-05-01  
0002.png,zebra,2024-05-03
```

- 이미지와 같은 폴더에 배치
- 지원 형식 — .csv · .jsonl · .parquet

작성 규칙

- file_name 열 필수 — 이미지와 정보를 연결
- 값은 metadata 파일 기준 상대 경로
- *_file_name 형태도 사용 가능
- 나머지 열 이름이 그대로 데이터셋 열이 됨

```
features:  
  ['image', 'species', 'date']  
ds[0]["species"] # 'cheetah'
```

Foundation Model

작업 유형에 따른 정답 기재 방식

분류는 폴더 이름, 그 외 작업은 metadata 파일

이미지 캡셔닝

```
# metadata.csv
file_name,text
0001.png,A golden retriever...
0002.png,A german shepherd
```

```
features: ['image', 'text']
```

- 이미지를 설명하는 **문장** 기재
- **text** 열 이름 → 데이터셋의 **text** 열
- 확인 — **ds[0]["text"]**

객체 탐지

```
# metadata.jsonl
{"file_name": "0001.png",
 "objects": {"bbox":
  [[302,109,73,52]],
 "categories": [0]}}
```

```
features: ['image', 'objects']
```

- **bbox** — 대상의 위치 좌표
- **categories** — 대상의 범주 번호
- 대상이 여러이면 목록으로 나열
- 값 구조가 복잡하여 **JSONL** 형식 사용

Foundation Model

업로드한 데이터로 실행

불러온 데이터셋을 추론과 학습에 그대로 사용

추론에 사용

```
from datasets import load_dataset
from transformers import pipeline

ds = load_dataset("dataset")
clf = pipeline("image-classification")
```

```
clf(ds["train"][0]["image"])
```

- 폴더 경로만 지정 — Hub 데이터셋과 동일한 방식
- 추론은 라벨 없이 이미지만으로 가능
- 결과 확인 — ds[0]["image"]

학습(미세조정)에 사용

```
labels = ds["train"].features["label"].names

trainer = Trainer(
    model=model,
    train_dataset=ds["train"],
    eval_dataset=ds["test"]
)
```

```
trainer.train()
```

- **추론** — 이미지만 있으면 됨, 라벨 폴더 불필요
- **학습** — train · test 구간과 정답 라벨 필요
- Hub 데이터셋과 사용법 동일 — 이름 자리에 폴더 경로
- 이후 절차는 앞 실습과 같음

Foundation Model

추론

추론

학습이 완료된 모델의 파라미터를 고정한 채, 새로운 입력에 대한 예측을 산출하는 과정

입력 이미지

사전학습 모델

예측 결과

추론의 정의


- **파라미터 고정** — 모델 안의 값을 바꾸지 않음
- **순전파만 수행** — 입력에서 출력까지 한 번만 통과
- **학습 과정 부재** — 정답 라벨·역전파 불필요
- 필요 입력은 모델과 입력 이미지뿐

사전학습 모델의 활용

- **파운데이션 모델** — 대규모 데이터로 사전학습 (pre-training) 완료
- 형태·질감·객체에 대한 범용 표현 (representation) 보유
- 추가 학습 없이 미보유 데이터에 일반화 가능
- 출력은 각 후보에 대한 예측 확률로 산출

Hugging Face의 추론

pipeline — 세 단계를 대신 처리한다



Foundation Model

pipeline이 대신 해주는 것

같은 작업, 두 가지 방법

직접 구현

```
from transformers import AutoImageProcessor
from transformers import AutoModelForImageClassification
from PIL import Image
import torch
MODEL = "google/vit-base-patch16-224"
# 1) 모델 · 전처리기 각각 불러오기
processor = AutoImageProcessor.from_pretrained(MODEL)
model = AutoModelForImageClassification.from_pretrained(MODEL)
# 2) 전처리 - 크기 조정 · 정규화 · 텐서 변환
image = Image.open("cat.jpg")
inputs = processor(images=image, return_tensors="pt")
# 3) 모델 실행
with torch.no_grad():
    logits = model(**inputs).logits
# 4) 후처리 - 점수 변환 · 상위 정렬 · 라벨 매칭
top5 = logits.softmax(dim=-1)[0].topk(5)
labels = [model.config.id2label[i.item()]] for i in top5.indices]
```

Pipeline

```
from transformers import pipeline
clf = pipeline("image-classification",
               Model="google/vit-base-patch16-224")
clf("cat.jpg")
```

- 전처리 · 실행 · 후처리를 한 줄로
- 라벨과 점수를 바로 반환
- 작업 이름만 바꾸면 재사용
- 모델 미지정 시 기본 모델 자동

Foundation Model

pipeline이 지원하는 작업

작업(task) 이름 변경만으로 다양한 작업 수행

비전 (Vision)

image-classification — 이미지 분류
object-detection — 객체 탐지
image-segmentation — 세그멘테이션
depth-estimation — 깊이 추정
image-to-text — 이미지 설명 생성
mask-generation — 마스크 생성
video-classification — 영상 분류

멀티모달 (Multimodal)

zero-shot-image-classification — 제로샷 이미지 분류
zero-shot-object-detection — 제로샷 객체 탐지
visual-question-answering — 이미지 질의응답
document-question-answering — 문서 질의응답
zero-shot-audio-classification — 제로샷 음성 분류

그 외 텍스트(분류·요약·번역·생성·질의응답) · 음성(인식·합성) 분야 15개

Foundation Model

실행 예시 — 이미지 분류

세 줄로 이미지의 종류를 판별

```
from transformers import pipeline  
clf = pipeline("image-classification")  
clf("cat.jpg")
```

1행 — pipeline 불러오기

2행 — 작업 이름 지정 (기본 모델 자동 준비)

3행 — 이미지 입력



결과 읽기

- 출력 형식 — 라벨(label)과 점수(score)의 목록
- 예: `tabby 0.51 / tiger cat 0.24`
- 점수 — 각 후보에 대한 예측 확률 (1에 가까울수록 확신 ↑)
- 상위 후보가 함께 제시됨 — 단일 정답이 아님

Foundation Model

추론 실습 1

Foundation Model

Hub에서 모델 찾기

필터와 정렬로 목적에 맞는 모델 검색

The screenshot shows the Hugging Face Models Hub interface. On the left, the 'Tasks' filter is highlighted with a red box, showing options like Text Generation, Any-to-Any, Image-Text-to-Text, Image-to-Text, Image-to-Image, Text-to-Image, Text-to-Video, and Text-to-Speech. Below the tasks, a 'Parameters' slider is visible, ranging from <1B to >500B. On the right, the 'Models' section displays a list of models with their respective details, including the model name, task, size, update time, and download/like counts. The models listed are thinkingmachines/Inkling, baidu/Unlimited-OCR, prism-ml/Ternary-Bonsai-27B-gguf, poolside/Laguna-S-2.1, DavidAU/Qwen3.6-27B-Fable-Fusion-711-Uncensored-Her..., and prism-ml/Bonsai-27B-gguf.

검색 절차

- ① huggingface.co → Models 탭
- ② 작업(Tasks) 필터에서 수행할 작업 선택
- ③ 파라미터 수 필터로 모델 규모 조절
- ④ 정렬 기준 선택 — 다운로드 · 트렌딩 · 최신
- ⑤ 이름 형식 확인 — 제작자/모델명


모델 카드 확인

- 용도 — 의도된 사용 목적
- 학습 데이터 — 어떤 데이터로 학습되었는가
- 한계와 편향 — 무엇을 못하는가, 어떤 치우침이 있는가
- 평가 결과 — 보고된 성능 수치
- 라이선스 — 사용 조건

Foundation Model

모델을 코드에 지정

Use this model 버튼으로 코드 복사



복사 절차

- ① 모델 페이지 우측 상단 **Use this model** 클릭
- ② 목록에서 **Transformers** 선택
- ③ 표시된 코드에서 모델 이름 확인
- ④ 코드의 **model=** 자리에 붙여넣기

이미지 분류 모델 예시

- **google/vit-base-patch16-224** — 표준 분류 모델
- **microsoft/resnet-50** — 널리 사용되는 기본 모델
- **facebook/deit-base-patch16-224**
- 세 모델 모두 ImageNet 1000종 분류 학습

Foundation Model

이미지 분류란

이미지 전체에 정해진 분류 중 하나의 이름을 붙이는 작업



정의

- 사진 한 장 전체를 보고 하나의 범주로 판단
- **분류 범위** — 모델이 학습한 이름 목록 안에서만 선택
- **세그멘테이션과 차이** — 부분이 아닌 전체를 판단

결과 형식

- 이름(label)과 점수(score)의 목록
- 점수가 높은 순으로 상위 후보 함께 제시

활용 분야

- **의료** — 영상에 라벨을 붙여 질병 징후 확인
- **환경** — 위성영상으로 삼림 감시 · 산불 탐지
- **농업** — 작물 상태 · 토지 이용 판별
- **생태** — 동식물 종 식별

Foundation Model

실습 — 이미지 분류

작업과 모델을 지정하여 이미지의 종류를 판별

```
# python
from transformers import pipeline
from PIL import Image

image = Image.open("cat.jpg")

clf = pipeline(
    task="image-classification",
    model="google/vit-base-patch16-224",
    device=0
)
```

task — 수행할 작업 이름
model — 앞서 선택한 모델
device — 연산 장치 (0=GPU, -1=CPU)
clf(image) — 준비한 이미지 입력

작업 (task)

필수 · 수행 내용 결정

모델 (model)

선택 · 생략 시 기본 모델 자동 준비

입력

경로 · 주소 · 이미지 객체 모두 가능

장치 (device)

선택 · 미지정 시 CPU에서 실행

결과 읽기

출력은 라벨과 점수의 목록

```
[{'score': 0.8821496367454529, 'label': 'Egyptian cat'},  
{ 'score': 0.07465527951717377, 'label': 'tabby, tabby cat'},  
{ 'score': 0.037991415709257126, 'label': 'tiger cat'},  
{ 'score': 0.0009538870654068887, 'label': 'lynx, catamount'},  
{ 'score': 0.00010449632100062445, 'label': 'tiger, Panthera tigris'}]
```

label — 모델이 예측한 분류 이름

score — 해당 분류에 대한 예측 확률

점수가 높은 순으로 정렬


기본 5개 후보 출력

결과 해석

- **점수** — 1에 가까울수록 확신이 큼 (전체 합 1)
- **상위 후보가 함께 제시** — 단일 정답이 아님
- **라벨은 영어로 출력** — 모델의 학습 분류 체계를 따름
- 상위 후보가 서로 유사하면 모델이 판단을 나눈 것

객체 탐지란

이미지 속 대상의 종류와 위치를 함께 찾는 작업



정의

- 대상마다 종류와 위치를 하나씩 출력
- **분류와 차이** — 전체가 아닌 개별 대상 단위
- 같은 종류가 여러 개면 각각 따로 검출

결과 형식

- 이름 · 점수 · 위치 상자(box)
- 상자는 좌표 네 개 — 좌측 상단이 기준점

활용 분야

- **자율주행** — 보행자 · 표지판 · 신호등 인식
- **의료 영상** — 병변 위치 표시
- **감시 · 보안** — 출입 인원 · 이상 상황 확인
- **검색** — 특정 대상이 있는 이미지 찾기

객체 탐지

작업 이름 변경만으로 대상의 위치까지 탐지

코드

```
from transformers import pipeline
from PIL import Image
image = Image.open("cat.jpg")
det = pipeline(
    task="object-detection",
    model="facebook/detr-resnet-50"
)
result = det(image)
result
```

- 앞 실습과 동일한 구조 — 작업 이름과 모델만 변경
- 이미지는 앞서 준비한 변수 그대로 사용

출력 형태

```
[{'score': 0.9987272620201111,
  'label': 'cat',
  'box': {'xmin': 176, 'ymin': 456,
          'xmax': 3496, 'ymax': 1946}}]
```

- **label** · **score** — 분류와 동일
- **box** — 대상의 위치 (사각형 좌표)
- 이미지 속 대상마다 하나씩 출력


Foundation Model

탐지 결과 시각화

좌표를 사각형으로 그려 위치 확인

```
from PIL import ImageDraw

draw_image = image.copy()
draw = ImageDraw.Draw(draw_image)
for r in result:
    box = r["box"]
    draw.rectangle(
        (box["xmin"], box["ymin"],
         box["xmax"], box["ymax"]),
        outline="red", width=3
    )
    draw.text(
        (box["xmin"], box["ymin"] - 12),
        r["label"], fill="red"
    )
```




- **image.copy()** — 원본 보존을 위한 사본 생성
- **ImageDraw.Draw** — 이미지에 그림을 그리는 도구
- **for r in result** — 탐지된 대상마다 반복
- **draw.rectangle** — 좌표 네 개로 사각형 그리기
- **draw.text** — 상자 위에 분류 이름 표시
- **outline · width** — 선 색상과 두께

Foundation Model

세그멘테이션이란

이미지를 영역으로 나누어 모든 픽셀을 대상에 대응시키는 작업



정의

- 이미지의 모든 픽셀을 각각 어떤 대상에 속하는지 대응
- **탐지와 차이** — 사각형이 아닌 대상의 실제 윤곽
- 결과는 영역을 칠한 마스크 이미지로 출력

활용 분야

- **의료 영상** — 장기 · 조직 구분, X선 · MRI 분석
- **자율주행** — 차선 · 장애물 등 도로 구조 인식
- **배경 제거** — 대상만 남기고 나머지 분리

연구 활용

- **면적 산출** — 병변 · 균열 · 경작지 등 넓이 계산
- **경계 추출** — 불규칙한 형태의 윤곽 확보

Foundation Model

세그멘테이션

사각형이 아닌 대상의 실제 윤곽을 따라 픽셀 단위로 구분

코드

```
from transformers import pipeline
from PIL import Image

image = Image.open("cat.jpg")

seg = pipeline(
    task="image-segmentation",
    model="facebook/detr-resnet-50-panoptic"
)

result = seg(image)
result
```

- 앞 실습과 동일한 구조 — 작업 이름과 모델만 변경

출력 형태

```
[{'score': 0.998772,
  'label': 'LABEL_199',
  'mask': <PIL.Image.Image
           image mode=L size=3640x2226>},
 {'score': 0.999483,
  'label': 'cat',
  'mask': <PIL.Image.Image
           image mode=L size=3640x2226>}]
```

- **label · score** — 앞 실습과 동일
- **mask** — 해당 영역을 표시한 흑백 이미지
- 구분된 영역마다 하나씩 출력
- 좌표(box)가 아닌 영역 자체를 반환

세그멘테이션 결과 시각화


마스크를 원본 이미지에 겹쳐 영역 확인

개별 마스크 확인

```
print("구분된 영역:", len(result))

for r in result:
    print(r["label"], round(r["score"], 3))

result[0]["mask"]
```



원본에 겹치기

```
overlay = image.convert("RGBA")
mask = result[0]["mask"]

color = Image.new(
    "RGBA", image.size, (255, 0, 0, 100)
)
overlay.paste(color, (0, 0), mask)

overlay
```



Foundation Model

제로샷 분류

학습에 사용되지 않은 분류 범주를 추론 시점에 지정하여 분류하는 방식


제로샷의 정의

- **제로샷(zero-shot)** — 학습 예시를 하나도 사용하지 않음
- 분류 범주를 추론 시점에 텍스트로 지정
- **파라미터 변경 없음** — 추론만 수행
- **대비** — 소수샷(few-shot)은 소량의 예시 제공

작동 원리

- 이미지·텍스트를 함께 학습한 모델 (**CLIP·SigLIP 등**)
- 이미지·후보 문구를 각각 **임베딩**으로 변환
- 같은 공간에서 비교 — **유사도 산출**
- 유사도가 가장 높은 후보를 결과로 반환

1. Contrastive pre-training



제로샷 분류 — 데이터 준비

데이터셋 불러오기

```
from datasets import load_dataset

ds = load_dataset(
    "imageomics/IDLE-00-Camera-Traps",
    split="test[:100]"
)
```

datasets — Hub 데이터셋 전용 라이브러리
첫 인자 — 데이터셋 이름 (제작자/데이터셋명)
split — 사용할 구간과 개수 지정

데이터셋과 split

- 카메라 트랩 이미지 **2,586**장, **142**종 — LILA BC 기반
- 구간은 **test** 하나
- "**test[:100]**" — 앞 100장만 내려받기
- "**test[:5%]**" — 비율로도 지정 가능

Foundation Model

제로샷 분류 — 데이터 준비

이미지와 후보 목록 확인

```
ds[0]["image"]  
  
print(ds[0]["common_name"])
```

ds[0] — 첫 번째 항목 선택

image — 화면에 이미지 표시

common_name — 해당 이미지의 정답 종 이름



ds[0]["image"] 출력 — 카메라 트랩 사진

제로샷 분류 — 데이터 준비

데이터 구조 확인

입력

ds

출력

```
Dataset({
  features: ['image', 'original_label',
            'scientific_name', 'common_name',
            'kingdom', 'phylum', 'cls',
            'order', 'family', 'genus',
            'species'],
  num_rows: 100
})
```

출력 항목

- **features** — 각 항목의 구성 열
- **num_rows** — 불러온 이미지 수
- **주요 열** — image(이미지) · common_name(일반명) · scientific_name(학명)
- **그 외** — 분류 계층 (강·목·과·속·종)
- 실습에서는 **image**와 **common_name** 사용

제로샷 분류 — 데이터 준비

이미지와 후보 목록 확인

이미지와 정답

```
ds[0]["image"]  
  
print(ds[0]["common_name"])
```

- **ds[0]** — 첫 번째 항목 선택
- **image** — 화면에 이미지 표시
- **common_name** — 해당 이미지의 정답 종 이름

후보 목록 생성

```
labels = sorted(set(ds["common_name"]))  
  
print(len(labels))  
print(labels[:5])
```

- **set** — 중복 제거하여 종 목록 생성
- **sorted** — 이름순 정렬
- 이 목록을 다음 실습의 후보로 사용

Foundation Model

실습 — 제로샷 분류

후보 목록을 지정하여 종을 예측

코드

```
from transformers import pipeline

clf = pipeline(
    task="zero-shot-image-classification",
    model="google/siglip-base-patch16-224"
)

result = clf(ds[0]["image"], candidate_labels=labels)
result[:5]
```

- 앞 실습과 동일한 구조 — 작업 이름·모델만 변경
- **candidate_labels** — 후보 목록 지정
- **ds · labels** — 앞 단계에서 준비한 데이터·목록

출력 형태

```
[{'label': 'cheetah', 'score': 0.8721},
 {'label': 'spotted hyena', 'score': 0.0413},
 {'label': 'donkey', 'score': 0.0198},
 ...]
```

- **label · score** — 앞 실습과 동일한 형식
- 후보 목록의 모든 항목에 점수 부여
- 점수가 높은 순으로 정렬

예측과 정답 비교

정답 라벨과 대조하여 예측 성능 확인

개별 확인

```
print("예측:", result[0]["label"])
print("정답:", ds[0]["common_name"])
print("점수:", result[0]["score"])
```

- `result[0]` — 점수가 가장 높은 예측
- 정답 열(`common_name`)과 나란히 출력

여러 장 확인

```
n = 20
correct = 0

for item in ds.select(range(n)):
    pred = clf(item["image"],
                candidate_labels=labels)
    if pred[0]["label"] == item["common_name"]:
        correct += 1

print("정확도:", correct / n)
```

- `select` — 지정한 개수만 선택
- 예측과 정답이 일치한 횟수를 집계
- 학습을 전혀 하지 않은 상태의 성능

Foundation Model

제로샷 분류

후보를 교체하면 동일 이미지에서 다른 판단 수행

코드

```
behaviors = [  
    "a picture of an animal eating",  
    "a picture of an animal moving",  
    "a picture of an animal resting",  
    "a camera trap picture of an animal eating",  
    "a camera trap picture of an animal moving",  
    "a camera trap picture of an animal resting",  
]
```



출력

```
[{'score': 0.9409,  
  'label': 'a camera trap picture of an animal eating'},  
 {'score': 0.9048,  
  'label': 'a camera trap picture of an animal resting'},  
 {'score': 0.8512,  
  'label': 'a camera trap picture of an animal moving'},  
 {'score': 0.0012,  
  'label': 'a picture of an animal moving'},  
 {'score': 0.0004,  
  'label': 'a picture of an animal eating'},  
 {'score': 0.0004,  
  'label': 'a picture of an animal resting'}]
```

- 'camera trap'을 넣은 세 후보가 모두 상위 — 이미지 종류와 문구가 맞아서
- 행동 구분보다 문구 형식의 영향이 큼

Foundation Model

추론 실습 2

Foundation Model

실습 — 이미지 분류

7개 비전 과제 · 실습 데이터셋 구성

작업	데이터	내용
① 이미지 분류	철도 궤도	궤도 표면 촬영 — 결함 · 정상 2종 · 이진 분류
② 객체 탐지	혈액 도말	현미경 촬영 — 적혈구 · 백혈구 · 혈소판 3종, 세포별 위치 정답 포함
③ 세그멘테이션	PCB 기판	인쇄회로기판 — 부품 · 배선 · 패드가 조밀하게 배치된 구조
④ 깊이 추정	일반 장면	실내외 일상 장면 — 하늘 · 도로 · 가구 등 150종
⑤ 이미지 설명 생성	일반 장면	④와 동일 데이터 — 앞선 전문 영상도 함께 입력
⑥ 문서 질의응답	재무 보고서	스캔 문서 — 예산서 · 명세서 등, 글자와 배치 정보 포함
⑦ 시각 질의응답	뇌 MRI	뇌종양 영상과 질문 · 답변 쌍

이미지 분류

이미지 전체를 하나의 범주로 판별

작업

- 입력 — 이미지 한 장
- 출력 — 라벨(label)과 점수(score)
- 점수가 높은 순으로 정렬 — 상위 후보 함께 제시
- 판별 범위 — 모델이 학습한 분류 체계 내

데이터와 모델

- 궤도 표면을 촬영한 점검용 이미지
- 범주 2종 — Defective(결함) · Non-defective(정상)
- 정답 라벨 포함 — 예측과 대조 가능
- 모델 — ViT 분류 모델



Defective



Non-defective

Foundation Model

실습 — 이미지 분류

궤도 이미지의 결함 여부 판별

```
from datasets import load_dataset
from transformers import pipeline

ds = load_dataset(
    "crangana/railroad-fault-detection",
    split="train[:100]"
)
labels = ds.features["label"].names
image = ds[0]["image"]

clf = pipeline(
    task="image-classification",
    model="crangana/railroad-fault-detector",
    device=0
)

clf(image)
```

결과 확인

출력 형태

```
[{'label': 'Defective', 'score': 0.97},
 {'label': 'Non-defective', 'score': 0.03}]
```

정답: Defective

정확도 측정

```
correct = 0
for item in ds:
    pred = clf(item["image"])[0]["label"]
    if pred == labels[item["label"]]:
        correct += 1

print("정확도:", correct / len(ds))
```

객체 탐지


대상의 종류와 위치를 함께 판별

작업

- 입력 — 이미지 한 장
- 출력 — 라벨 · 점수 · 위치 상자(box)
- 대상마다 하나씩 출력 — 개수 파악 가능
- 좌표 기준 — 이미지 좌측 상단이 (0, 0)

데이터와 모델

- 현미경으로 촬영한 혈액 도말 이미지
- 범주 3종 — rbc(적혈구) · wbc(백혈구) · platelets(혈소판)
- 세포마다 위치 상자가 정답으로 포함
- 한 장에 세포 수십 개 — 개수 계산 가능
- 모델 — DETR 탐지 모델



```
{ "id": [ 2567, 2568, 2569, 2570, 2571, 2572, 2573, 2574, 2575, 2576 ], "area": [ 6321, 5187, 5278, 8512, 6321, 10384, 4440, 3932,
```

Foundation Model

실습 — 객체 탐지

혈액세포의 종류와 위치 검출

코드

```
ds = load_dataset(
    "keremberke/blood-cell-object-detection",
    name="full", split="train[:100]")
image = ds[0]["image"]

det = pipeline(
    task="object-detection",
    model="theodullin/detr-resnet-50_"
        "finetuned_blood_cell_15epochs",
    device=0
)

result = det(image, threshold=0.5)

print("검출:", len(result))
result[:3]
```

결과 확인

출력 형태

검출: 42

```
[{'label': 'rbc', 'score': 0.98,
  'box': {'xmin': 12, 'ymin': 45,
          'xmax': 78, 'ymax': 110}}, ...]
```

범주별 개수

```
from collections import Counter
Counter(r["label"] for r in result)
{'rbc': 38, 'wbc': 2, 'platelets': 2}
```

라벨.점수는 분류와 동일 — box만 추가
세포 종류별 개수를 자동 집계

탐지 결과 시각화

예측 상자와 정답 상자의 대조

코드

```
from PIL import ImageDraw


img = image.copy().convert("RGB")
draw = ImageDraw.Draw(img)

# 정답 - 초록
for box in ds[0]["objects"]["bbox"]:
    x, y, w, h = box
    draw.rectangle((x, y, x + w, y + h),
                   outline="lime", width=2)

# 예측 - 빨강
for r in result:
    b = r["box"]
    draw.rectangle((b["xmin"], b["ymin"],
                    b["xmax"], b["ymax"]),
                   outline="red", width=2)
```

확인 사항

- **초록** — 데이터에 포함된 정답 위치
- **빨강** — 모델이 예측한 위치
- **두 상자가 겹칠수록** 정확한 예측
- **놓친 세포 · 잘못 잡은 영역 확인**



Foundation Model

세그멘테이션


픽셀 단위로 영역의 경계를 구분

작업

- 입력 — 이미지 한 장
- 출력 — 영역 마스크(mask) — 대상 흰색, 배경 검은색
- 탐지와의 차이 — 사각형이 아닌 대상의 실제 윤곽
- 마스크는 이미지 형태 — 화면에 그대로 표시 가능

데이터와 모델

- 인쇄회로기판(PCB)을 촬영한 검사용 이미지
- 부품 · 배선 · 패드가 조밀하게 배치된 구조
- **모델 — SAM**(Segment Anything Model)
- SAM은 범주를 학습하지 않음 — 경계만 검출
- 결과에 이름이 없음 — 무엇인지는 판별하지 않음



실습 — 세그멘테이션

PCB 기판의 영역 경계 검출

코드

```
ds = load_dataset(
    "keremberke/pcb-defect-segmentation",
    name="full", split="train[:50]"
)
image = ds[0]["image"]

seg = pipeline(
    task="mask-generation",
    model="facebook/sam-vit-base",
    device=0
)

out = seg(image, points_per_batch=32)

print("검출된 영역:", len(out["masks"]))
out["masks"][0]
```

결과 확인

출력 형태

검출된 영역: 87

out["masks"] - 마스크 목록 (흑백)
out["scores"] - 각 마스크의 신뢰도

원본에 겹치기

```
from PIL import Image


overlay = image.convert("RGBA")
color = Image.new("RGBA", image.size,
                  (255, 0, 0, 100))
overlay.paste(color, (0, 0), out["masks"][0])
```

- 마스크 — 대상은 흰색, 나머지는 검은색
- 라벨이 없음 — 번호로만 구분

Foundation Model

깊이 추정이란

사진 한 장으로 무엇이 가깝고 먼지를 판단하는 작업



정의

- 사진 한 장에서 원근을 추정 — 특수 장비 불필요
- **결과** — 밝을수록 가깝고 어두울수록 먼 흑백 이미지

주의할 점

- **상대 깊이** — 어느 쪽이 더 가까운지만 알 수 있음
- 실제 거리(m)는 알 수 없음 — 단위 없는 값
- 거리 측정이 목적이면 적합하지 않음

활용 분야

- **로봇 · 자율주행** — 장애물까지의 원근 파악
- **사진 편집** — 배경 흐림(인물 모드) 효과
- **3D 복원** — 사진에서 입체 구조 추정
- **증강현실** — 가상 물체를 장면에 배치

깊이 추정

단일 이미지에서 대상까지의 상대 거리를 추정

작업

- 입력 — 이미지 한 장
- 출력 — 깊이 지도(이미지) · 수치 배열
- 밝을수록 가까움 · 어두울수록 멀리
- 상대 깊이 — 단위 없음, 절대 거리 아님
- 작업 이름 — **depth-estimation**

데이터와 모델

- 실내외 일상 장면 이미지
- 150개 범주 — 하늘 · 도로 · 사람 · 가구 등
- 일반 장면 — 학습 데이터와 성격 유사
- 모델 — **DPT**(Dense Prediction Transformer)

Foundation Model

실습 — 깊이 추정

일반 장면의 원근 추정

코드

```
ds = load_dataset(
    "mervel/scene_parse_150",
    split="train[:50]"
)
image = ds[0]["image"]

depth = pipeline(
    task="depth-estimation",
    model="Intel/dpt-hybrid-midas",
    device=0
)

out = depth(image)
out["depth"]
```

결과 확인

```
from PIL import Image

w, h = image.size
pair = Image.new("RGB", (w * 2, h))
pair.paste(image.convert("RGB"), (0, 0))
pair.paste(out["depth"].convert("RGB"), (w, 0))
pair
```



Foundation Model

이미지 설명 생성이란

이미지의 내용을 문장으로 서술하는 작업



A group of different animals are grazing in the wild.
A group of wild animals in a field outside
A herd of of wild animals walking around a field surrounded by forest.
Zebras, giraffes and kudus on the run across a plain.
it is a savannah with zebras and giraffes.

정의

- 사진을 보고 내용을 문장으로 만들어 냄
- **분류와 차이** — 정해진 이름이 아닌 자유로운 문장

주의할 점

- 생성 방식 — 실행할 때마다 표현이 달라질 수 있음
- 일상 사진으로 학습 — 전문 영상은 서술이 빈약
- 사실 확인 필요 — 그럴듯한 오답 가능

활용 분야

- **접근성** — 시각장애인용 이미지 대체 텍스트
- **검색** — 사진에 설명을 붙여 검색 가능하게
- **자료 정리** — 대량 이미지에 설명 자동 부여

이미지 설명 생성

이미지의 내용을 문장으로 서술

작업

- 입력 — 이미지 한 장
- 출력 — 생성된 문장 **generated_text**
- 라벨이 아닌 자유 형식 서술 — 정해진 범주 없음
- 생성 방식 — 실행할 때마다 표현이 달라질 수 있음

데이터와 모델

- 실내외 일상 장면 이미지 — ④와 동일 데이터
- 앞선 실습의 전문 영상(궤도 · 혈액 · 기판)도 함께 입력
- 모델 — 이미지 인코더 + 문장 생성기 결합 구조
- 일상 사진으로 학습 — 서술 범위가 그에 좌우

Foundation Model

실습 — 이미지 설명 생성

일반 장면과 전문 영상의 서술 비교

코드

```
ds = load_dataset(  
    "mervel/scene_parse_150",  
    split="train[:50]"  
)  
image = ds[0]["image"]  
  
cap = pipeline(  
    task="image-to-text",  
    model="nlpconnect/vit-gpt2-  
        image-captioning",  
    device=0  
)  
  
cap(image)
```

결과 확인



a street vendor selling a variety of colorful items




a broken down brick wall with a fire hydrant

Foundation Model

문서 질의응답이란

문서 이미지에 질문하여 필요한 값만 뽑아내는 작업



정의

- 스캔 문서에 질문을 던져 답을 얻음
- 입력** — 문서 이미지 + 질문 문장
- 특징** — 글자와 배치를 함께 인식

주의할 점

- 문서에 없는 정보를 물으면 엉뚱한 답
- 표·서식이 복잡하면 정확도 하락

활용 분야

- 행정·회계** — 청구서·명세서에서 금액 추출
- 기록물 정리** — 스캔 자료에서 항목 추출
- 서류 처리** — 대량 문서에서 특정 값 수집

연구 활용

- 설문지·기록표 스캔본의 항목 수집
- 별도 OCR 도구 없이 바로 질문 가능

문서 질의응답

문서 이미지에 질문하여 답을 추출

작업

- 입력 — 문서 이미지 + 질문
- 출력 — 답변 **answer**
- 문서의 글자와 배치를 함께 인식
- 문서에 없는 정보는 답할 수 없음

데이터와 모델

- 재무 문서를 촬영 · 스캔한 이미지
- 예산서 · 명세서 · 보고서 등 업무 문서
- 문서 내 글자와 배치 정보 포함
- **모델 — Donut**(Document Understanding Transformer)
- OCR 도구 없이 이미지에서 직접 판독

Foundation Model

실습 — 문서 질의응답

재무 문서에서 항목별 정보 추출

코드

```
ds = load_dataset(
    "Anas989898/Vision-OCR-
    Financial-Reports-10k",
    split="train[:50]"
)
doc = ds[0]["image"]

qa = pipeline(
    task="document-question-answering",
    model="naver-clova-ix/donut-base-
    finetuned-docvqa",
    device=0
)

qa(image=doc,
    question="What is the total amount?")
```

결과 확인

출력 형태

```
[{'answer': '1,250,000'}]
```

질문 바꿔보기

```
questions = [
    "What is the total amount?",
    "What is the date?",
    "Who is the issuer?",
]

for q in questions:
    print(q)
    print(" →", qa(image=doc,
        question=q)[0]["answer"])
```

- 같은 문서 · 다른 질문 → 다른 답변
- 문서에 없는 정보를 물으면 엉뚱한 답 산출

Foundation Model

시각 질의응답이란

일반 이미지에 자유롭게 질문하여 답을 얻는 작업



정의

- 사진에 질문을 던져 답을 얻음
- **문서 질의응답과 차이** — 문서가 아닌 일반 사진
- **답변 형태** — 단어 수준의 짧은 답 + 점수

주의할 점

- 일상 사진으로 학습 — 전문 영상은 학습 범위 밖
- 모르는 것도 답을 내놓음 — 점수로 확신 정도 확인

활용 분야

- **접근성** — 사진 내용을 음성으로 안내
- **자료 검수** — 사진에 특정 요소가 있는지 확인
- **교육** — 이미지 기반 문답 자료 제작

Foundation Model

시각 질의응답

같은 질문, 다른 모델 — 학습 데이터가 답을 결정한다

작업

- **입력** — 이미지 + 질문 (㉔ 문서 QA와 동일 구조)
- **출력** — 답변
- 문서가 아닌 일반 이미지 대상
- 정답 답변 포함 — 모델 답변과 대조 가능

두 모델을 비교

구분	ViLT	BLIP-LoRA
학습 데이터	일상 사진	방사선 영상
답변 방식	후보 중 선택	문장 생성
출력	단어 + 점수	서술 문장
도구	pipeline	직접 호출

Foundation Model

실습 — 시각 질의응답

의료 영상에 질문하여 답변 확인

코드

```
ds = load_dataset(
    "Kaith-jeet123/brain_tumor_vqa",
    split="train[:50]"
)
image = ds[0]["image"]

vqa = pipeline(
    task="visual-question-answering",
    model="dandelin/vilt-b32-
        finetuned-vqa",
    device=0
)

vqa(image=image,
    question="Is there a tumor?")
```

결과 확인

출력 형태

```
[{'answer': 'yes', 'score': 0.71},
 {'answer': 'no', 'score': 0.18},
 {'answer': 'maybe', 'score': 0.04}]
```

일반 질문과 비교

```
for q in ["What color is this?",
          "How many objects are there?",
          "Is this a medical image?"]:
    print(q, "→",
          vqa(image=image,
              question=q)[0]["answer"])
```

Foundation Model

실습 — 시각 질의응답 ②

pipeline이 지원하지 않는 모델은 직접 호출한다

코드

```
from transformers import BlipProcessor,
    BlipForQuestionAnswering

MED = "dineshcr7/Final-BLIP-LORA_VQA_RAD"

med_proc = BlipProcessor.from_pretrained(
    "Salesforce/blip-vqa-base")
med_model = BlipForQuestionAnswering \
    .from_pretrained(MED).to(device)
med_model.eval()

def ask_med(img, question):
    inputs = med_proc(img.convert("RGB"),
        question, return_tensors="pt"
    ).to(device)
    with torch.no_grad():
        out = med_model.generate(
            **inputs, max_new_tokens=32)
    return med_proc.decode(out[0],
        skip_special_tokens=True)
```

왜 직접 호출하나

pipeline의 범위

- 지원 대상 — 표준 작업과 구조의 모델
- 미지원 모델 — 처리기와 모델을 개별 호출
- 확인 방법 — 모델 카드의 사용 예제 참조

직접 호출의 세 단계

- ① **처리기** — 이미지와 질문을 모델 입력으로
- ② **generate** — 답변을 문장으로 생성
- ③ **decode** — 숫자를 글자로

전처리 · 모델 실행 · 후처리를 직접 쓴 것

Foundation Model

이미지 미세 조정

미세조정


사전학습 모델의 파라미터를 보유 데이터로 갱신하여 특정 작업에 적응시키는 과정

미세조정의 정의

- 사전학습 모델을 출발점으로 사용 — 무작위 초기화에서 시작하지 않음
- 보유 데이터로 **파라미터 갱신** 수행
- **지도학습 방식** — 정답 라벨을 기준으로 예측과의 차이를 조정
- 결과물 — 해당 작업에 **특화된 모델**

처음부터 학습과의 차이

- **처음부터 학습** — 무작위 상태에서 시작, 대량 데이터·장시간 소요
- **미세조정** — 사전학습으로 확보한 범용 표현을 재사용
- **소량 데이터**로도 특정 작업 적응 가능
- **학습 시간·계산 자원 절감**



추론과 미세조정

파라미터 갱신 여부에 따른 구분

추론

- **파라미터 고정** — 모델이 변하지 않음
- **입력** — 이미지만
- **수행** — 예측 산출 (순전파 1회)
- **결과물** — 예측값, 모델은 그대로
- **도구** — **pipeline**

미세조정

- **파라미터 갱신** — 모델이 변함
- **입력** — 이미지 + 정답 라벨
- **수행** — 예측·비교·조정의 반복
- **결과물** — 특화된 새 모델
- **도구** — **Trainer**

학습 범위에 따른 구분

갱신 대상 파라미터의 범위에 따른 두 방식

	전체 미세조정	PEFT
갱신 대상	모든 파라미터	일부·추가 파라미터
원본 파라미터	변경	대부분 유지
학습 비용	높음	낮음
필요 데이터	많음	적음
저장 용량	원본과 동일	변경분만 별도 보관

전체 미세조정


- 모델 전체를 보유 데이터에 맞추어 조정
- 데이터가 충분한 경우 성능 우수

PEFT (Parameter-Efficient Fine-Tuning)

- 소수의 파라미터만 학습하는 방식의 총칭
- 부분 미세조정 · LoRA 등이 이에 해당

전체 미세조정

사전학습 파라미터 전체를 보유 데이터로 갱신



- **백본(backbone)** — 이미지의 특징을 추출하는 부분, 블록의 누적
- **분류 헤드(head)** — 추출된 특징으로 최종 판단을 내리는 부분
- **전체 미세조정** — 백본과 헤드 모두 갱신


방식과 특징

- **사전학습 가중치를 초기값으로 사용**
- **분류 헤드 교체** — 보유 분류 체계에 맞게 새로 구성
- **성능** — 데이터가 충분한 경우 가장 우수
- **비용** — 학습 시간·메모리 소요 큼
- **데이터** — 소량인 경우 과적합 위험
- **결과물** — 원본과 동일한 크기의 새 모델

Foundation Model

부분 미세조정

백본의 일부 또는 전부를 동결하고 나머지만 학습



방식과 특징


- **근거** — 백본은 형태·질감 등 범용 표현을 이미 보유
- **상위 블록** — 작업에 특화된 표현, 해제 시 성능 향상 여지
- **비용** — 학습 대상에 비례, 헤드만 학습 시 매우 빠름
- **데이터** — 소량으로도 수행 가능
- **결과물** — 동결된 부분은 공유, 학습한 부분만 별도 보관

- **동결(freeze)** — 파라미터를 갱신하지 않음
- **최소 범위** — 헤드만 학습, 선형 프로빙(linear probing)
- **확장** — 상위 블록부터 순차적으로 해제
- **하위 블록일수록 범용 표현 보유** — 동결 유지

Foundation Model

LoRA

원본 파라미터를 유지한 채 소형 행렬을 추가하여 학습



방식과 특징

- **학습 파라미터** — 전체의 수 % 이내
- **성능** — 동일 조건에서 전체 미세조정에 근접
- **저장** — 원본은 공유, 추가분만 별도 보관 (수십 MB 수준)
- **교체** — 용도별 모듈을 갈아 끼워 사용 가능
- **원본 보존** — 사전학습 표현이 변경되지 않음

- **A** — 추가 학습 모듈
- **원본 블록** — 전부 동결
- 각 블록 내부의 특정 가중치에 소형 행렬 삽입
- 학습 대상 — 추가한 행렬뿐
- 추론 시 원본 출력과 추가분을 합산

Hugging Face의 미세조정

Trainer — 사전학습 모델을 학습에 사용하는 표준 도구

Trainer의 정의

- 학습 루프(training loop)를 표준화한 구현체
- 미니배치 · 순전파 · 역전파 · 갱신을 자동 수행
- 지정 항목 — 모델 · 하이퍼파라미터 · 데이터셋
- 하이퍼파라미터는 **TrainingArguments**로 정의

학습 과정

- ① 미니배치 구성 — 학습 데이터를 일정 크기로 분할
- ② 순전파 — 입력에서 출력 방향으로 계산, 예측 산출
- ③ 손실 계산 — 손실 함수로 예측과 정답의 차이 측정
- ④ 역전파 — 손실에 대한 파라미터의 기울기 계산
- ⑤ 파라미터 갱신 — 옵티마이저가 학습률에 따라 조정

pipeline

추론
순전파 1회
작업 · 모델 · 입력
고정

Trainer

학습
순전파 + 역전파 반복
모델 · 하이퍼파라미터 · 데이터셋
갱신

용도
수행 연산
지정 항목
모델 파라미터

Foundation Model

이미지 미세 조정 실습

실습 절차 비교

추론 실습과 비교한 미세조정 실습의 추가 절차

추론 실습

- ① 이미지 준비
- ② 모델 선택
- ③ pipeline 실행
- ④ 결과 확인

- 필요 항목 — 이미지와 모델
- 정답 라벨 불필요
- 소요 시간 — 즉시

미세조정 실습

- ① 데이터 준비 ← 정답 라벨 필요
- ② 구간 분리 ← 학습용 / 평가용
- ③ 전처리 ← 모델 입력 형식 통일
- ④ 모델 구성 ← 백본 + 새 분류 헤드
- ⑤ 학습 범위 지정 ← 백본 동결
- ⑥ 학습 조건 설정 ← 반복 횟수 · 학습률
- ⑦ 학습 실행 ← Trainer
- ⑧ 결과 확인 ← 전후 비교

- 필요 항목 — 이미지 · 정답 라벨 · 모델
- 평가용 데이터 별도 확보
- 소요 시간 — 학습 대기 발생

Foundation Model

미세조정 실습 구성

같은 데이터 · 같은 절차 — 학습 범위만 달리하여 두 방식을 비교

실습	데이터	학습 대상	학습 비율	확인 사항
① 부분 미세조정	Food-101 · 5,000장	백본 동결 + 새 헤드	0.09%	정확도 1% → 92%
② LoRA	①과 동일	백본에 LoRA 모듈 삽입	0.7%	정확도 1% → 94%

왜 미세조정이 필요한가

- 사전학습 모델의 분류 체계에 없는 대상은 추론만으로 판별 불가
- **실습에서 확인** — 요리 사진에 접시 · 국자 등 주변 사물로 응답
- 보유 데이터로 소량만 학습시켜 해당 분류를 수행하게 만들



Food-101 데이터셋 불러오기와 구간 분리

실습 데이터셋 준비

코드

```
from datasets import load_dataset

ds = load_dataset(
    "ethz/food101",
    split="train[:5000]"
)

ds = ds.train_test_split(
    test_size=0.2, seed=42
)
ds
```

- 요리 사진 분류 데이터셋 — 101개 범주
- 전체 10만 장 중 **5,000장**만 사용
- **train_test_split** — 학습용·평가용 분리
- **seed=42** — 동일한 분할 재현
(전원 동일 결과)

출력

```
DatasetDict({ train: 4000장 · test: 1000장 })
```

Foundation Model

범주 이름과 정답 구조 확인

라벨 확인

코드

```
labels = ds["train"].features["label"].names

print("범주 수:", len(labels))
print("정답:",
      labels[ds["train"][0]["label"]])

ds["train"][0]["image"]
```

- `features["label"].names` — 범주 이름 목록
- 정답은 번호로 저장 — 이름 목록과 대조 필요
- 이미지와 정답을 눈으로 확인
- 이후 예측 결과 해석의 기준

사전학습 분류 모델의 예측 결과

미세조정 전 — 예측 확인

코드

```
from transformers import pipeline

clf = pipeline(
    task="image-classification",
    model="google/vit-base-patch16-224"
)

clf(ds["test"][0]["image"])
```

ImageNet 1000종으로 학습된 분류 모델

결과

```
[{'label': 'plate',      'score': 0.31},
 {'label': 'soup bowl', 'score': 0.18},
 {'label': 'ladle',     'score': 0.07}]
```

정답: beignets

- 요리 이름이 아닌 라벨 출력
- **원인** — 학습 분류 체계에 요리 범주 부재
- 접시·국자 등 주변 사물로 예측

Foundation Model

이미지 전처리

형식을 맞추고 · 데이터를 늘린다

형식 통일

- 크기 — 224×224 , 모델마다 상이
- 채널 — RGB 3채널, 흑백도 3채널로
- 값의 범위 — 정규화
- 형식 — 텐서(tensor)



AutoImageProcessor — 규칙 자동 적용
학습·추론에 같은 규칙 — 어긋나면 성능 저하

데이터 증강

한 장을 여러 장치럼
좌우 반전 · 회전 · 밝기 조정 · 일부 잘라내기

왜 하나


- 데이터가 적을 때 과적합을 줄임
- 20장 → 수백 장의 효과



Foundation Model

백본과 분류 헤드

몸통은 물려받고, 머리만 새로 만든다



항목	백본	분류 헤드
하는 일	이미지에서 특징을 뽑음	그 특징으로 이름을 정함
사전학습	이미 학습됨	1000종용 — 재사용 불가
학습 대상	그대로 사용 · 동결	101종용으로 새로 구성
상태	수억 장을 학습한 상태	아무것도 모르는 상태

모델 입력 형식에 맞춘 이미지 변환

전처리

코드

```
from transformers import AutoImageProcessor

ckpt = "google/vit-base-patch16-224-in21k"
processor = AutoImageProcessor.from_pretrained(ckpt)

def transform(batch):
    images = [img.convert("RGB") for img in batch["image"]]
    out = processor(images, return_tensors="pt")
    out["labels"] = batch["label"]
    return out

ds = ds.with_transform(transform)
```

- **ViT-in21k** — ImageNet-21k로 사전학습된 백본 (분류 헤드 없음)
- **AutoImageProcessor** — 모델별 전처리 규칙 자동 적용
- **수행** — 크기 조정 · 정규화 · 형식 변환
- **convert("RGB")** — 흑백 이미지도 3채널로 통일
- **with_transform** — 사용 시점에 변환, 메모리 절약

Foundation Model

모델 구성

사전학습 백본과 새 분류 헤드로 모델 구성

코드

```
from transformers import \
    AutoModelForImageClassification

model = AutoModelForImageClassification \
    .from_pretrained(
        ckpt,
        num_labels=len(labels),
        id2label={i: n for i, n in enumerate(labels)},
        label2id={n: i for i, n in enumerate(labels)},
    )
```

헤드 확인


```
print(model.classifier)
Linear(in_features=768, out_features=101)
```

- **AutoModelForImageClassification** — 백본 + 분류 헤드 구조를 자동 구성
- **백본** — 체크포인트의 사전학습 가중치로 채워짐
- **분류 헤드** — 채울 값이 없어 무작위 초기화
- **num_labels** — 헤드의 출력 개수 (101)
- **id2label · label2id** — 번호와 이름의 대응
- **확인** — 768(백본 출력) → 101(요리 범주)

Foundation Model

학습의 진행 방식

예측 → 비교 → 조정을 반복한다



4,000장을 모두 돌면 → 1 epoch · 3회 반복

세 가지 설정

설정	의미	실습 값	조정 기준
num_train_epochs	전체를 몇 번 반복	3	성능이 안 오르면 중단
per_device_train_batch_size	한 번에 몇 장	32	메모리 부족 시 줄임
learning_rate	한 번에 얼마씩 조정	1e-3	손실이 안 줄면 먼저 조정

Foundation Model

학습 전 모델의 평가 데이터 정확도

미세조정 전 — 정확도 측정

코드

```
import torch

def accuracy(model):
    correct = 0
    for item in ds["test"]:
        x = item["pixel_values"].unsqueeze(0)
        with torch.no_grad():
            pred = model(x).logits.argmax(-1).item()
        if pred == item["labels"]:
            correct += 1
    return correct / len(ds["test"])

print("학습 전 정확도:", accuracy(model))
```

결과와 의미

학습 전 정확도: 0.012

- 헤드가 무작위 초기화 상태 — 예측이 무작위 수준
- 101종 중 찍기 확률 $\approx 1\%$
- 결과가 이와 유사 — 아직 학습되지 않았음을 확인
- 이 값이 미세조정 성과의 기준선

백본 동결과 학습 대상 확인

학습 범위 지정

코드

```
for p in model.vit.parameters():
    p.requires_grad = False

total = sum(p.numel() for p in model.parameters())
train = sum(p.numel() for p in model.parameters()
            if p.requires_grad)

print(f"전체: {total:,}")
print(f"학습: {train:,} ({train/total:.2%})")
```

결과와 의미

전체: 85,875,173
학습: 77,669 (0.09%)

- **requires_grad = False** — 파라미터를 갱신하지 않음
- **model.vit** — 백본 부분
- **학습 대상** — 분류 헤드뿐
- 앞서 다룬 부분 미세조정 방식

학습 설정

코드

```
from transformers import TrainingArguments

args = TrainingArguments(
    output_dir="food_model",
    num_train_epochs=3,
    per_device_train_batch_size=32,
    learning_rate=1e-3,
    remove_unused_columns=False,
    logging_steps=20,
)
```

- **num_train_epochs** — 전체 데이터 반복 횟수
- **per_device_train_batch_size** — 한 번에 처리할 이미지 수
- **learning_rate** — 한 번에 조정하는 정도
- **remove_unused_columns=False** — 이미지 열 유지에 필수
- **output_dir** — 결과 저장 폴더

Trainer를 통한 학습 수행

학습 실행

코드

```
from transformers import Trainer

trainer = Trainer(
    model=model,
    args=args,
    train_dataset=ds["train"],
    eval_dataset=ds["test"],
)

trainer.train()
```

진행 표시 읽기

Step	Training Loss
20	4.31
40	3.52
60	2.98

- **Loss(손실)** — 예측과 정답의 차이
- 값이 감소하면 학습이 진행 중
- 감소가 멈추면 추가 학습 효과 미미
- 진행률 막대로 남은 시간 확인

Foundation Model

학습 전후 예측과 정확도 비교

미세조정 후 — 결과 비교

예측

```
clf_new = pipeline(  
    "image-classification",  
    model=model,  
    image_processor=processor)  
  
clf_new(ds["test"][0]["image"])
```

```
beignets 0.87 / churros 0.05  
정답: beignets
```

정확도

```
print("학습 후 정확도:",  
      accuracy(model))
```

```
학습 전: 0.012  
학습 후: 0.79
```

- 같은 이미지 — 엉뚱한 라벨에서 정답으로
- 1,000장 정확도 — 1% → 79%
- 분류 헤드만 학습한 결과

학습한 모델의 저장 및 활용

모델 저장과 재사용

저장

```
trainer.save_model("food_model")  
processor.save_pretrained("food_model")
```

- 모델과 전처리 규칙을 함께 저장
- 폴더 하나로 관리

재사용

```
clf = pipeline(  
    task="image-classification",  
    model="food_model"  
)  
  
clf("my_photo.jpg")
```

- 저장한 폴더를 모델 이름 자리에 지정
- 이후에는 추론과 동일한 방식으로 사용
- Hub 업로드 — `push_to_hub("계정명/모델명")`

LoRA 실습

앞 실습과 동일한 데이터·절차, 모델 구성만 변경

코드

```
from peft import LoraConfig, get_peft_model

model = AutoModelForImageClassification \
    .from_pretrained(
        ckpt,
        num_labels=len(labels),
        id2label=id2label, label2id=label2id,
    )
```

- **peft** — PEFT 기법 전용 라이브러리
- LoRA · 어댑터 · 프롬프트 튜닝 등 지원
- 학습되지 않은 모델을 다시 구성 — 동일 조건 비교

앞 실습과의 차이

그대로 사용

- **데이터셋** — 동일한 구간 분리 결과
- **전처리** — 동일한 processor
- **학습 도구** — Trainer, 동일한 절차

달라지는 부분

- **모델 구성** — LoRA 모듈 삽입
- **학습 범위** — 헤드 + 백본 내부 모듈
- 동결 코드 불필요 — 자동 처리

삽입 위치와 규모 지정

코드

```
config = LoraConfig(
    r=16,
    lora_alpha=16,
    target_modules=["query", "value"],
    lora_dropout=0.1,
    bias="none",
    modules_to_save=["classifier"],
)

model = get_peft_model(model, config)
```

- **LoraConfig** — LoRA 적용 조건 정의
- **get_peft_model** — 원본 모델에 모듈을 삽입한 형태로 변환

주요 항목

- **r** — 추가 모듈의 규모, 클수록 표현력·파라미터 증가
- **target_modules** — 삽입 위치, 어텐션의 query · value
- **lora_alpha** — 추가분의 반영 강도
- **lora_dropout** — 과적합 방지 비율
- **modules_to_save** — LoRA 외에 함께 학습할 부분
 - 분류 헤드는 새로 생성되었으므로 반드시 포함

LoRA 실습

학습 파라미터 비율 확인

코드

```
model.print_trainable_parameters()
```

결과

```
trainable params: 372,485  
all params: 86,247,658  
trainable%: 0.4319
```

- **print_trainable_parameters** — 학습 대상 파라미터 수와 비율 출력
- **학습 대상** — 삽입한 LoRA 모듈 + 분류 헤드
- 원본 백본은 동결 상태

방식별 비교

방식	학습 대상	비율
전체 미세조정	전체	100%
부분 미세조정	헤드만	0.09%
LoRA	모듈 + 헤드	0.7%

- 부분 미세조정보다 학습 대상 증가
- 백본 내부까지 조정 — 성능 향상 여지
- **r** 값 조정으로 학습 규모 변경 가능

앞 실습과 동일한 절차로 학습 수행

코드

```
args = TrainingArguments(  
    output_dir="food_lora",  
    num_train_epochs=3,  
    per_device_train_batch_size=32,  
    learning_rate=5e-4,  
    remove_unused_columns=False, logging_steps=20,  
)  
trainer = Trainer(  
    model=model, args=args,  
    train_dataset=ds["train"], eval_dataset=ds["test"]  
)
```

설정 비교

- 학습 절차 — 앞 실습과 동일
- 데이터·전처리 — 변경 없음
- **learning_rate** — 헤드만 학습할 때보다 낮게 설정
- **근거** — 백본 내부까지 조정하므로 급격한 변화 방지
- **그 외 항목** — 동일하게 유지하여 조건 통제

방식별 성능과 비용 비교

정확도 측정

```
print("LoRA 정확도:", accuracy(model))
```

저장

```
model.save_pretrained("food_lora")
```

- 앞 실습과 동일한 함수로 측정 — 동일 기준 비교
- 저장 시 추가분만 보관 (수 MB)

종합 비교

방식	학습 대상	정확도	저장
학습 전	—	0.01	—
부분 미세조정	0.09%	0.92	수 MB
LoRA	0.7%	0.947	수 MB

- 학습 범위 확대에 따른 성능 변화 확인
- 소요 시간과 성능의 균형 판단
- 데이터 규모가 작으면 차이가 작을 수 있음

SAM 미세조정

마스크 디코더만 학습하여 의료 영상에 적응

SAM의 특성

- 프롬프트 기반 — 점 · 박스로 대상을 지정하여 분할
- 사전학습 규모 — 이미지 1,100만 장, 마스크 10억 개
- 범용성 — 범주를 학습하지 않아 어떤 영상에도 적용
- 한계 — 의료 영상은 학습에 포함되지 않음

분류가 아닌 분할 작업

- 출력이 라벨이 아니라 마스크
- 헤드 교체 대신 디코더 학습

학습 범위

비전 인코더

89.7M 동결

프롬프트 인코더

6.2K 동결

마스크 디코더

4.1M 학습

학습 대상 — 전체의 약 4.3%

- 인코더는 이미 풍부한 시각 특징 보유
- 도메인 적응은 디코더에서 발생

실습 — SAM 미세조정

정답 마스크에서 박스 프롬프트 추출

코드

```
from datasets import load_dataset
from transformers import SamProcessor

ds = load_dataset(
    "kowndinya23/Kvasir-SEG", split="train[:400]")

processor = SamProcessor.from_pretrained(
    "facebook/sam-vit-base")

item = ds[0]
item["image"] # 내시경 이미지
item["annotation"] # 정답 마스크
```

박스 프롬프트 추출

```
box = get_bounding_box(mask, shift=20)
# [x_min, y_min, x_max, y_max]
```

Kvasir-SEG

- 대장내시경 용종 이미지 1,000장
- 의료 전문가가 픽셀 단위로 주석
- 용종 크기 편차 큼 — 화면의 1%에서 50%까지
- 조기 대장암 진단과 직결

박스 프롬프트

- SAM은 프롬프트를 받아 분할 — 점 · 박스 · 마스크
- 학습 시 정답 마스크에서 박스를 자동 추출
- $\pm 20\text{px}$ 무작위 흔들기 — 부정확한 입력에 대비
- 평가 시에는 흔들지 않음 (shift=0) — 공정한 비교

실습 — SAM 미세조정

마스크 디코더만 학습 후 전후 비교

코드

```
model = SamModel.from_pretrained(
    "facebook/sam-vit-base").to(device)

# 인코더 동결
for name, p in model.named_parameters():
    if name.startswith(("vision_encoder",
                        "prompt_encoder")):
        p.requires_grad_(False)

loss_fn = DiceBCELoss(dice_weight=0.5)
optimizer = AdamW(
    model.mask_decoder.parameters(), lr=5e-5
)
```

- **Trainer 미사용** — 학습 루프 직접 작성
- **손실 = Dice + BCE 결합**

두 손실을 함께 쓰는 이유

- 용종은 화면의 일부 — 배경 픽셀이 압도적
- **BCE만 사용 시**
 - “대부분 배경”으로 기울어 경계가 뭉개짐
- **Dice** — 겹치는 영역을 직접 최적화

결과 비교 (20장 평균)

미세조정 전 Dice: **0.6296**

미세조정 후 Dice: **0.8267**